

**Выполнил:** Круглов А. С. (kruglovyf310@yandex.ru).

**Направление:** RL for locomotion incl. sim-to-real gap, energy-efficient locomotion, hierarchical systems, and physically-consistent pipelines.

**Задача:** подобрать наиболее релевантные статьи на выбранную тему. Найти и обосновать открытую проблему, заслуживающую внимания, и сформулировать гипотезу для преодоления этого барьера.

**Замечание:** в ходе решения поставленной задачи для поиска, анализа и перевода использовались известные ИИ инструменты. При написании данного отчета ИИ не применялся.

## СОДЕРЖАНИЕ

|     |                                                  |    |
|-----|--------------------------------------------------|----|
| 1   | Выбор статей.....                                | 2  |
| 1.1 | Обоснование выбора статьи №1 .....               | 2  |
| 1.2 | Обоснование выбора статьи №2 .....               | 2  |
| 1.3 | Обоснование выбора статьи №3 .....               | 3  |
| 2   | Анализ методов .....                             | 4  |
| 2.1 | Анализ метода RMA .....                          | 4  |
| 2.2 | Анализ метода Fine-Tuning.....                   | 7  |
| 2.3 | Анализ метода CMS .....                          | 9  |
| 3   | Практическая реализация метода Fine-Tuning ..... | 14 |
|     | ИСПОЛЬЗОВАННЫЕ ИСТОЧНИКИ .....                   | 17 |

## **1 Выбор статей**

В качестве критериев отбора статей послужили:

- соответствие тематики статьи и выбранного направления;
- год публикации (последние 3–5 лет);
- статус издания, в котором опубликована статья;
- статус автора (научная степень, количество публикаций);
- количество цитирований.

Год публикации, статус автора и количества цитирований были определены при помощи ресурса [scholar.google.com](https://scholar.google.com).

### **1.1 Обоснование выбора статьи №1**

Название: «RMA: Rapid Motor Adaptation for Legged Robots» [1].

Тема: Разработка метода адаптации локомотионного робота к изменениям среды, минимизирующего влияние sim-to-real переноса на производительность на основе RL обучения исключительно в симуляции.

Год публикации: 2021.

Издание: сборник работ конференции «Robotics: Science and Systems».

Авторы: Kumar A. – PhD, UC Berkeley, Malik J. – Professor, UC Berkeley.

Количество цитирований: 854.

По данным сайта [www.conferenceranks.com](http://www.conferenceranks.com) конференция RSS имеет категорию A\* (флагманская конференция, ведущее мероприятие в своей области) по классификации ERA.

Также одним из факторов выбора данной статьи для рассмотрения является наличие публичного репозитория с инструкциями для запуска представленного решения.

### **1.2 Обоснование выбора статьи №2**

Название: «Legged Robots that Keep on Learning: Fine-Tuning Locomotion Policies in the Real World» [2].

Тема: Разработка алгоритма тонкой подстройки стратегии передвижения робота в реальном мире, направленного на адаптацию к параметрам среды, не представленным в симуляции или представленным в объеме, не обеспечивающем требуемую производительность.

Год публикации: 2021.

Издание: сборник работ конференции «IEEE International Conference on Robotics and Automation» (ICRA).

Авторы: Smith L. – PhD, UC Berkeley, Levine S. – Associate Professor, UC Berkeley.

Количество цитирований: 167.

По данным сайта [www.conferenceranks.com](http://www.conferenceranks.com) конференция ICRA имеет категорию A1 (наиболее влиятельная в своей области) по классификации Qualis.

Инструкции для запуска представленного в статье решения также находятся в публичном репозитории.

### **1.3 Обоснование выбора статьи №3**

Название: «Learning Visual Locomotion with Cross-Modal Supervision» [3].

Тема: Разработка алгоритма обучения локомоционного робота автономной ходьбе на основе визуальной информации, обходящего проблемы, связанные с моделированием RGB-данных в симуляции.

Год публикации: 2023.

Издание: сборник работ конференции «IEEE International Conference on Robotics and Automation» (ICRA).

Авторы: Loquercio A. – PhD, UC Berkeley / Assistant Professor, UPenn, Kumar A. – PhD, UC Berkeley, Malik J. – Professor, UC Berkeley.

Количество цитирований: 60.

## 2 Анализ методов

Далее методы, представленные в статьях, рассматриваются в приведенном выше порядке в разрезе ядра решения и анализа недостатков. Также для каждого метода сформулированы гипотезы для преодоления выявленных барьеров.

### 2.1 Анализ метода RMA

В статье достаточно подробно описан алгоритм работы метода. Для подкрепления обоснованности выявленных в дальнейшем недостатков необходимо кратко, но с сохранением основных концепций описать ядро решения.

#### 2.1.1 Краткое описание ядра решения

Схемы обучения и развертывания приведены на рисунке 1.




Рисунок 1 – Схемы обучения и развертывания метода RMA

Обучение происходит исключительно в симуляции без какого-либо дообучения или настройки в реальном мире и разделено на две фазы.

Во время первой фазы происходит обучение политики  $\pi$ , которая принимает на вход текущее проприоцептивное состояние  $x_t$ , предыдущее действие

$a_{t-1}$ , и латентный вектор параметров среды  $z_t$ , сгенерированный кодировщиком  $\mu$  на основе точных данных о конфигурации среды  $e_t$ .

$\pi$  и  $\mu$  представляют из себя многослойные перцептроны, обученные при помощи обучения с подкреплением (RL).

Во время второй фазы происходит обучение модуля адаптации  $\varphi$ , задача которого состоит в предсказании латентного вектора параметров среды  $\hat{z}_t$  по истории состояний и действий, собранных при выполнении текущей политики. Данная архитектура обусловлена тем, что знание привилегированной конфигурации среды  $e_t$  и ее закодированного вектора  $z_t$  будут недоступны во время развертывания в реальном мире.

Цель обучения модуля адаптации состоит в минимизации ошибки между предсказанным вектором  $\hat{z}_t$  и действительным  $z_t$ . Обучение проводится методом обучения с учителем на данных, собранных при выполнении политики  $\pi$  с использованием текущих предсказаний самого модуля  $\varphi$ .

Для возможности развертывания в разных по структуре средах предусмотрена случайная генерация разнообразного по своим свойствам рельефа во время обучения.

Функция наград при обучении включает в себя вознаграждение за удержание заданной скорости поступательного движения вперед и штрафы за боковое движение и вращение, резкие контакты ног с землей, нарушение плавности движения, проскальзывание стоп и резкое изменение угла тангажа.

На этапе развертывания в реальном мире принцип работы аналогичен второй фазе обучения.

Модуль адаптации  $\varphi$  генерирует вектор  $\hat{z}_t$  на частоте 10 Гц, а базовая политика генерирует желаемые положения сочленений на частоте 100 Гц, которые преобразуются в крутящие моменты с помощью PD-контроллера робота. Разница в частотах обусловлена тем, что на практике такое асинхронное выполнение не ухудшает производительность, потому что  $\hat{z}_t$  в реальном мире меняется относительно редко. При этом базовая политика  $\pi$  всегда будет использовать самый последний вектор  $\hat{z}_t$ .

### 2.1.2 Выявленные недостатки

Первым выявленным недостатком является отсутствие адаптации к изменениям параметров среды при помощи зрения или, другими словами, отсутствие возможности предсказывать будущие резкие изменения рельефа.

Этим недостатком можно отчасти объяснить указанное падении успешность при прохождении возвышающихся препятствий. Так при преодолении препятствия высотой 8 см. успешность составляет 60% в то время, как процент успешных подъемов на высоту 6 см. составляет 100%. Подтверждение показано на рисунке 2.




Рисунок 2 – Успешность при подъеме на разную высоту

### 2.1.3 Гипотеза для преодоления выявленного барьера RMA

Недостаток, связанный с отсутствием зрительного восприятия, может быть нивелирован включением в обучающие данные не только проприоцептивных данных, но и данных с камер, установленных на роботе.

Как описано в статье [3], имитация RGB изображения в симуляции не может в полной мере передать свойства реального мира. Наиболее возможным вариантом выглядит использование камер, передающих карты глубин изображения, так как в таком случае качество обучения будет зависеть не от качества симулированных текстур, освещения и цвета, а от геометрии объектов и расстояния.

Архитектура RMA может быть дополнена отдельным кодировщиком наподобии  $\mu$ , который будет обрабатывать карты глубины и извлекать из них латентный вектор, характеризующий геометрию рельефа перед роботом. Полученный вектор будет подаваться на вход модуля адаптации  $\phi$  вместе с проприоцептивными данными. Таким образом,  $\phi$  будет оценивать  $\hat{z}_t$  не только на основе того, как робот уже движется, но и на основе того, по чему ему предстоит идти. Это может позволить политике  $\pi$  заранее адаптироваться к будущим препятствиям.

## 2.2 Анализ метода Fine-Tuning

Несмотря на то, что в статье решение описывается на уровне концепций без подробного технического описания, этого достаточно для понимания сути метода и его недостатков.

### 2.2.1 Краткое описание ядра решения

Основная идея метода заключается в постоянном обучении нескольких политик (движение вперед, движение назад, восстановление при падении) в реальном мире, предварительно обученных в симуляции. Структура метода приведена на рисунке 3.




Рисунок 3 – Структура метода Fine-Tuning

Стратегии обучаются путем имитации референсных движений, полученных при помощи технологии захвата движений собаки. Обучение построено на основе off-policy RL-алгоритма, в основе которого лежит архитектура Актор-Критик.

Функция вознаграждения представляет из себя сумму из следующих наград:

- соответствие вращения суставов референсному вращению;
- соответствие скорости суставов референсной скорости;
- соответствие положения стоп референсному положению;
- соответствие положения корпуса референсному положению;
- соответствие скорости корпуса референсной скорости.

Параметры геометрии рельефа при обучении не изменяются, а изменяются только параметры робота.

При развертывании в реальном мире обучение политик продолжается, что позволяет адаптировать движение к неизвестной среде. Все данные о новых переходах (действие-состояние) сохраняются в буфер, на основе которого происходит обучение в реальном мире.

### 2.2.2 Выявленные недостатки

Основным недостатком, в том числе указанным авторами является сброс буфера при переходе в сильно отличающуюся от предыдущей среду развертывания. Это говорит о том, что «продолжающееся обучение», заявленное в названии статьи возможно только для одной конкретной или в значительной степени похожих сред, а также о том, что отсутствует накопление общего опыта.

Робот, обученный данным методом, может перемещаться в разнообразных средах, но в каждой новой среде ему придётся обучаться заново.

Упомянутый в анализе предыдущего метода недостаток, связанный с отсутствием зрения также актуален.

### 2.2.3 Гипотеза для преодоления выявленных барьеров Fine-Tuning



Для сохранения и использования опыта из разных сред можно заменить один единый буфер на множество буферов, связанных с определённым кластером семантических признаков.

Новый опыт автоматически распределяется между всеми буферами, но с разным весом: большая часть попадает в буферы с наиболее похожим контекстом, а меньшая — в буферы для схожих условий. Это создаёт перекрытие данных между похожими средами.

При обучении политики для текущей среды будут использоваться в основном данные из наиболее релевантного буфера, с добавлением части опыта из семантически близких буферов. Это позволит политике эффективно адаптироваться к новым условиям, одновременно сохраняя и используя общие принципы, выявленные в прошлом, что предотвратит полное забывание предыдущих навыков.

Для возможности сохранения признаков ранее не встречающихся сред нужно предусмотреть динамическое создание новых буферов для принципиально новых условий. Это позволит роботу обучаться непрерывно.

## 2.3 Анализ метода CMS

Данный метод берет за основу обучения в симуляции алгоритм, аналогичный RMA, но при переносе в реальность учится опираться на визуальную информацию.

### 2.3.1 Краткое описание ядра решения

Так как в симуляции крайне сложно создать правдоподобное RGB отображение реального мира, вместо визуального ввода используются латентные представления, вычисляемые из точных данных симулятора. Процесс обучения описан ниже.

В симуляции последовательно обучаются две политики —  $\pi_{слепая}$  (в оригинале  $\pi_{blind}$ ) и  $\pi$  — политика с предвидением. Далее  $\pi_{слепая}$  будет обозначаться

как  $\pi_c$ . Способ обучения аналогичен тому, что представлен в верхней части рисунка 1.

Обе политики принимают состояние  $x_t$ , вектор  $z_t$  и информацию о поверхности  $\gamma_t$ , чтобы предсказывать целевые углы суставов  $a_t$  на частоте 100 Гц, которые затем преобразуются в моменты с помощью PD-контроллера. Политика с предвидением  $\pi$  принимает дополнительный вход  $\gamma_{t+\Delta t}$ , который является оценкой поверхности на расстоянии 15 см перед роботом.

На первом этапе обучается  $\pi_c$ , кодировщик геометрии  $\delta$ , который вычисляет  $\gamma_t$  и кодировщик среды  $\mu$ .

После этого веса  $\delta$  и  $\mu$  замораживаются и обучается  $\pi$ .

В результате обучения имеем две политики:  $\pi_c$ , которая работает только на проприоцептивных данных и  $\pi$ , которая принимает как данные состояния робота, так и данные о геометрии поверхности перед ним.

Алгоритм работы при развертывании в реальном мире представлен на рисунке 4.




Рисунок 4 – Схема работы CMS в реальном мире

После развертывания за движения робота некоторое время отвечает  $\pi_c$ . В это время происходит сбор набора данных, состоящего из  $l_t$  – визуального входа с камеры,  $x_t$  – текущего проприоцептивного состояния и  $\gamma_t$  – текущей оценки геометрии поверхности.

Этот набор данных используется для обучения свёрточной нейронной сети  $g_i$ . Её задача – оценивать будущую геометрию поверхности  $\gamma_{t+\Delta t}$  с помощью обучения с учителем, как показано на рисунке 5.




Рисунок 5 – Вычисление ошибки обучения

Целью обучения  $g_i$  является минимизация ошибки между предсказанной будущей геометрией и геометрией этой же точки, вычисленной кодировщиком  $\delta$ , в момент достижения её роботом.

После этого управление роботом берет на себя политика с предвидением  $\pi$ , на вход которой поступает предсказанное  $g_i$  значение  $\gamma_{t+\Delta t}$ . Это позволяет роботу использовать зрение для планирования движения. Данный процесс повторяется итеративно. Улучшенная политика собирает более качественные данные для дальнейшего обучения  $g_i$ .

### 2.3.2 Выявленные недостатки

Алгоритм CMS обучает только визуальный модуль на реальных данных, в то время как политика управления движением обучается исключительно в симуляции и не адаптируется к реальному миру. Это означает, что робот не учится физически лучше ходить на основе реального опыта, а улучшается только его способность видеть и предсказывать рельеф.

Следующим выявленным недостатком является отсутствие роста успешности модели с увеличением дальности видимости, о чём свидетельствует таблица 1.

Таблица 1. Зависимость метрик от дальности видимости

| Look Ahead    | Success ( $\uparrow$ ) | TTF ( $\uparrow$ ) | Distance (m) ( $\uparrow$ ) | Smoothness ( $\downarrow$ ) |
|---------------|------------------------|--------------------|-----------------------------|-----------------------------|
| 0cm (RMA [1]) | 58%                    | 0.83               | 4.11                        | 34.19                       |
| 5cm           | 64%                    | 0.88               | 4.67                        | 44.30                       |
| 15cm          | 75%                    | 0.95               | 4.73                        | 30.77                       |
| 25cm          | 74%                    | 0.96               | 4.96                        | 37.19                       |
| 35cm          | 74%                    | 0.94               | 4.66                        | 31.43                       |

Этот факт может являться ограничением для движения на более высокой скорости, при котором важна ранняя реакция на препятствия.

### 2.3.3 Гипотеза для преодоления выявленных барьеров CMS

Возможным решением проблемы статичности политики управления движением может быть добавление в архитектуру модуля адаптации  $\phi$  последнего полносвязного слоя, который не будет задействован в симуляции.

Веса данного слоя будут обнуляться в начале развертывания, а затем будет происходить дообучение на основе собранных данных в реальном мире для того, чтобы скорректировать выводы модуля адаптации  $\phi$ .

Обучение может осуществляться за счет минимизации ошибки между текущим предсказанным значением вектора  $\hat{z}_t$  и среднего значения предыдущих предсказаний. То есть адаптивный слой будет дообучаться, чтобы минимизировать резкие, необоснованные скачки в предсказаниях

Это позволит за начальный период работы в реальном мире адаптировать робота к неизвестной или несколько отличающейся от симуляции среде.

Решением проблемы отсутствия роста успешности модели с увеличением дальности видимости может являться приведение алгоритма CMS к иерархической структуре.

Помимо ближнего модуля предсказания  $g_i$  можно внедрить дальний модуль предсказания, предсказывающий не геометрию, а абстрактный вектор стратегии для дальнего горизонта (несколько метров).

Основная задача этого модуля будет заключаться в предсказании сложности будущего маршрута и возможного способа его прохождения.

При его обучении в качестве целевых данных будут использоваться не геометрические параметры, а фактическая успешность прохождения участка пути.

Это должно помочь политике принятия решения о будущем действии робота заранее адаптировать свое поведение на дальний участок маршрута.

### 3 Практическая реализация метода Fine-Tuning

Были проведены обучение и развертывание в симуляции модели робота Unitree A1 в соответствии с инструкциями, содержащимися в связанном со статьей репозитории.

На рисунке 6 представлено окно интерактивного демонстрационного интерфейса Bullet Physics ExampleBrowser, в котором визуализировались процессы обучения и развертывания. Цветная модель – обучаемый робот, серая – референсная траектория.




Рисунок 6 – Окно Bullet Physics ExampleBrowser

Обучение заняло 5 ч. 32 мин. Количество итераций было равно 1322. Для каждой итерации обучения в терминал выводились метрики, представленные на рисунке 7. Значение метрик:

- Iteration, номер итерации обучения;
- Wall\_Time, время выполнения итерации;
- Samples, общее количество перехода, записанных за итерацию;
- Train\_Return, среднее значение накопленной награды;
- Train\_Paths, количество эпизодов в тренировочной фазе;

- Test\_Return, среднее значение накопленная награды в тестовых эпизодах;
- Test\_Paths, количество эпизодов в тестовой фазе;
- Final\_Robot\_X / Y, конечные координаты робота в пространстве (вероятно, в метрах);
- Robot\_Travel\_Forward, перемещение робота вперёд;
- Robot\_Travel\_Sideways, перемещение вбок;
- Robot\_Travel\_Yaw\_Deg, угол рысканья робота;
- Max\_Torque, максимальное значение момента привода;
- Critic\_Loss, значение функции потерь сети Критика;
- Critic\_Steps, количество шагов обновления сети Критика;
- Critic\_Time\_Per\_Update, время на одно обновление сети Критика;
- Actor\_Loss, значение функции потерь сети Актора;
- Actor\_Entropy, энтропия политики (мера стохастичности действий);
- Actor\_Steps, количество шагов обновления сети Актора;

100%

|                        |         |
|------------------------|---------|
| Iteration              | 32      |
| Wall_Time              | 0.382   |
| Samples                | 39270   |
| Train_Return           | 6.34    |
| Train_Paths            | 1616    |
| Test_Return            | 1.54    |
| Test_Paths             | 1       |
| Final_Robot_X          | -0.696  |
| Final_Robot_Y          | -0.38   |
| Robot_Travel_Forward   | 0.0567  |
| Robot_Travel_Sideways  | -0.0546 |
| Robot_Travel_Yaw_Deg   | 15.8    |
| Max_Torque             | 30.2    |
| Critic_Loss            | 0.00558 |
| Critic_Steps           | 17182   |
| Critic_Time_Per_Update | 0.016   |
| Actor_Loss             | -1.77   |
| Actor_Entropy          | -5.74   |
| Actor_Steps            | 17182   |

Рисунок 7 – Метрики обучения

После выполнения тестового запуска в терминал выводится награда за тест и дополнительная информация. Выведенная информация приведена на рисунке 8.

```
Test_Return: 326.089
Test_Paths: 2.000
logged to: output/2026-02-06_2333_22/log_all_episodes.npz
numActiveThreads = 0
stopping threads
Thread with taskId 0 exiting
Thread TERMINATED
destroy semaphore
semaphore destroyed
destroy main semaphore
main semaphore destroyed
finished
numActiveThreads = 0
btShutDownExampleBrowser stopping threads
Thread with taskId 0 exiting
Thread TERMINATED
destroy semaphore
semaphore destroyed
destroy main semaphore
main semaphore destroyed
```

Рисунок 8 – Выведенная информация после выполнения тестового запуска

Так как тестирование выполняется в среде, геометрия поверхности не отличается от обучающей, отсутствует возможность оценить качество алгоритма подстройки.

Команда запуска обучения не предусматривает указание параметров, отвечающих за изменение рельефа обучения или тестирования.

Для оценки качества работы алгоритма необходимо было бы запустить тестирование в симуляции с изменением рельефа. Также способом проверки может быть запуск политики на реальном роботе, в данный момент, к сожалению, являющийся недоступным.

Видео демонстрации обучения и тестирования представлены в [репозитории](#).



## ИСПОЛЬЗОВАННЫЕ ИСТОЧНИКИ

1. Ashish Kumar, Zipeng Fu, Deepak Pathak, Jitendra Malik. RMA: Rapid motor adaptation for legged robots. *Robotics: Science and Systems*, 2021.
2. L. Smith, J. C. Kew, X. Bin Peng, S. Ha, J. Tan and S. Levine, "Legged Robots that Keep on Learning: Fine-Tuning Locomotion Policies in the Real World," 2022 International Conference on Robotics and Automation (ICRA), Philadelphia, PA, USA, 2022, pp. 1593-1599, doi: 10.1109/ICRA46639.2022.9812166.
3. A. Loquercio, A. Kumar and J. Malik, "Learning Visual Locomotion with Cross-Modal Supervision," 2023 IEEE International Conference on Robotics and Automation (ICRA), London, United Kingdom, 2023, pp. 7295-7302, doi: 10.1109/ICRA48891.2023.10160760.